INSTITUTO DE COMPUTAÇÃO - UNICAMP

MO810A/MC959A - Sistemas Multiagentes com Modelos de Linguagem

Prof. Dr. Julio Cesar dos Reis

Fase 2 - Metodologia

Correção de redações do ENEM com agentes especialistas

Artur Dias de Oliveira - 252635
Henrique Cazarim Meirelles Alves - 244763

IC/UNICAMP
2026

1 Visão Geral da Metodologia

Na Proposta, o problema a ser explorado foi a dificuldade de oferecer a estudantes correções frequentes, detalhadas e justificadas de redações do ENEM. Esse cenário decorre da sobrecarga de trabalho por docente no ensino médio (INEP, 2025a) e da superficialidade de sistemas monolíticos de agentes de IA, muitas vezes baseados em um único *prompt*, que tendem a produzir avaliações holísticas e injustificadas (KAMALOV et al., 2026). O projeto se alinha ao ODS 4 (Educação de Qualidade) e ao ODS 10 (Redução das Desigualdades), ao buscar democratizar o acesso a *feedback* de qualidade para a prática da escrita dissertativo-argumentativa. Desde então não houve ajustes de escopo, o projeto mantém o foco na avaliação técnica de redações por competência, acompanhada de justificativas pedagógicas, sem simular o ambiente de prova nem substituir o professor.

O fluxo completo da solução é apresentado na Figura 1. A entrada do sistema é um par (tema, redação), ambos em texto puro. Um agente orquestrador recebe o par e o distribui a cinco agentes especialistas, cada um responsável por uma competência do ENEM. Cada especialista atua com contexto e instruções próprios, baseados na rubrica oficial da sua competência, e produz uma nota acompanhada de justificativa sustentada em trechos da redação. Em seguida, um agente revisor, que adota o paradigma *LLM-as-a-judge*, avalia criticamente cada nota e cada justificativa, verificando se a análise se sustenta nos trechos citados e se está coerente com a rubrica. Quando identifica falhas, o revisor devolve a avaliação ao especialista correspondente para revisão, o que reduz alucinações e avaliações excessivamente positivas. Por fim, o orquestrador concilia eventuais inconsistências entre as notas e consolida os resultados. A saída entregue ao estudante é um relatório com a nota de cada competência (de 0 a 200 pontos, totalizando até 1000), as devidas justificativas e eventuais orientações de melhoria em linguagem didática.

A abordagem multiagente se mostra a mais adequada ao problema por três razões encontradas na literatura. Primeiro, a literatura indica que a divisão da avaliação em subtarefas especializadas e a síntese de múltiplas avaliações superam soluções individuais, reduzindo inconsistência, alucinação e avaliações excessivamente positivas (KAMALOV et al., 2026). Segundo, a especialização por rubrica favorece a explicabilidade, já que cada nota nasce de um agente cujo critério é explícito e auditável, além de permitir a utilização de modelos menores, reduzindo custo e latência (ABUJADALLAH; SAAD; ABUDALFA, 2025). Por último, a modularidade contribui para a manutenibilidade do sistema, uma vez que a separação por funções permite que mudanças e correções sejam realizadas sem que a atuação de outro agente seja afetada.

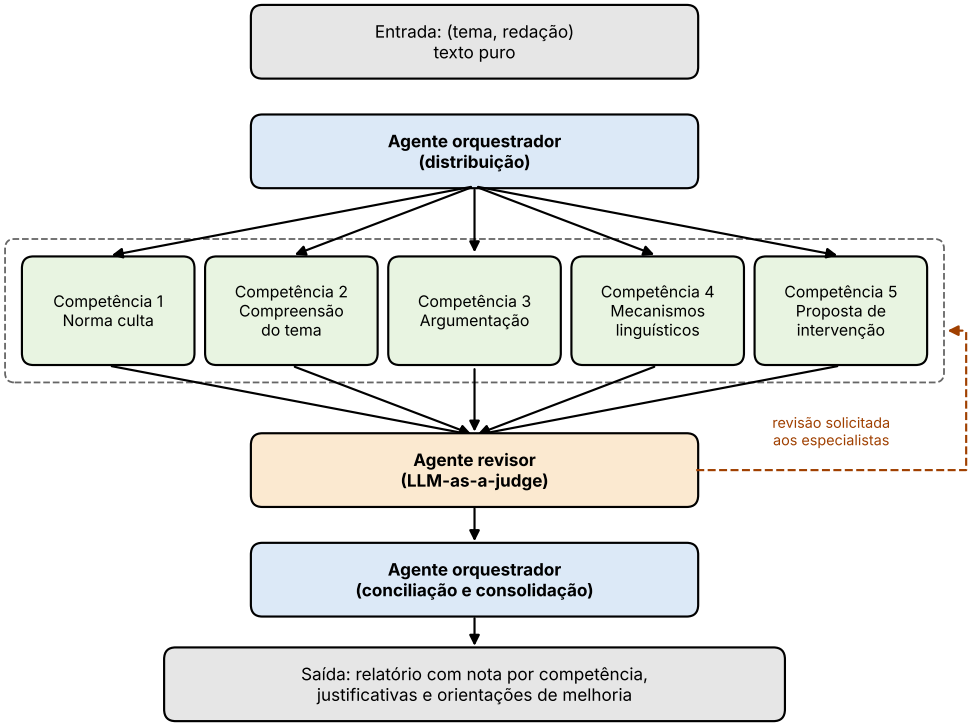


Figura 1: Arquitetura multiagente proposta para a correção de redações do ENEM. O contorno tracejado agrupa os cinco agentes especialistas, que produzem nota e justificativa ancorada em trechos da redação. A seta tracejada indica o ciclo de revisão solicitado pelo agente revisor.

2 Conjunto de Dados para a Avaliação

2.1 Fonte dos dados

A avaliação do projeto será realizada com o Essay-BR, resultado do trabalho de Marinho, Anchiêta e Moura (2021), uma coletânea pública de 4570 redações dissertativo-argumentativas, escritas em sua maior parte por estudantes do ensino médio e corrigidas por avaliadores especialistas segundo os cinco critérios do ENEM.

Marinho, Anchiêta e Moura (2022) ainda disponibilizam uma versão estendida deste *dataset*, com as mesmas características descritas anteriormente. Neste há 6577 redações, grande parte repetidas do anterior.

As redações foram coletadas pelos autores por meio de *web scraping* de dois sites públicos do portal UOL entre dezembro de 2015 e abril de 2020. No presente trabalho, os dados são obtidos diretamente dos repositórios desenvolvidos nos artigos acima e utilizados para avaliar o sistema e ajustar seus *prompts*.

2.2 Formato e restrições de uso

Os dados estão estruturados de maneira que cada amostra do *dataset* contenha um identificador para o tema da redação, um título (opcional), a redação escrita como uma lista de parágrafos, as notas por competência e a nota final (soma das notas por competência). Esta estruturação dos dados possibilita a avaliação de cada agente especialista individualmente, uma vez que a nota atribuída por ele pode ser diretamente mapeada à nota atribuída por um corretor humano.

O repositório é *open source* e os autores reforçam que as redações dos sites de origem são públicas e podem ser usadas para fins de pesquisa (MARINHO; ANCHIÊTA; MOURA, 2021). O uso neste trabalho se restringe à pesquisa acadêmica, para fornecer estruturação sólida na avaliação do desempenho do sistema multiagentes.

2.3 Pré-processamento

As redações são utilizadas com o mínimo de intervenção, pois erros de ortografia, acentuação, pontuação e uso de maiúsculas são justamente os objetos avaliados pela Competência I. Por isso, não se aplicam técnicas como conversão para minúsculas, remoção de acentos ou *stemming*, que apagariam os fenômenos a serem avaliados. As etapas aplicadas, implementadas em um *script* reprodutível, são:

1. **Leitura dos campos serializados.** As listas de parágrafos são lidas e os parágrafos são unidos, separados por linha em branco. Os textos referentes aos temas recebem o mesmo tratamento. Já as notas por competência também são lidas e armazenadas para comparação com as notas preditas por cada agente.

2. **Normalização de espaços.** São convertidos os espaços não separáveis (elemento HTML *' '*), colapsados os espaços duplicados e removidos os espaços antes de sinais de pontuação. Esses padrões são provavelmente resíduos da extração web e poderiam ser interpretados pelo agente responsável pela Competência I como erros de pontuação do estudante. Ortografia, acentuação e caixa permanecem inalteradas.

3. **Exclusão de textos em caixa alta.** Redações com mais de 20% das letras em maiúsculas foram removidas. O emprego de letras maiúsculas e minúsculas é critério da Competência I e seria penalizado pelo agente, porém a nota humana dessas redações não indicam tal penalização. Em uma dessas redações, as letras maiúsculas acentuadas foram perdidas (por exemplo, "PBLICA"), o que introduziria erros inexistentes no texto original.

4. **Remoção de duplicatas.** Não há duplicatas exatas. Após normalização (minúsculas e remoção de pontuação), há um par de redações idênticas do mesmo tema, com notas totais distintas (960 e 880). As duas foram removidas, pois o rótulo de referência é ambíguo.

Após essas etapas, separamos o conjunto total em conjuntos de treino, validação e teste com proporção 70/15/15. O conjunto de treino é usado para ajustar os *prompts* e os parâmetros dos agentes, o de validação como *proxy* do de teste e o de teste é reservado para a avaliação final, evitando assim o viés de construção.

2.4 Qualidade, viés e dados sensíveis

Uma análise prévia dos dados foi realizada visando interpretar a qualidade dos rótulos e a presença de viés, de representatividade e de dados sensíveis.

- **Qualidade dos rótulos.** Marinho, Anchiêta e Moura (2021) informam que as redações foram corrigidas por especialistas segundo os critérios do ENEM, mas não reportam o número de avaliadores nem uma medida de concordância entre eles. As notas dos sites de origem foram convertidas para a escala do ENEM, portanto os rótulos devem ser entendidos como uma referência humana sujeita a ruído, e não como verdade absoluta.

- **Viés e representatividade.** As redações foram enviadas a portais online de prática, de modo que a amostra reflete quem utiliza esses portais e pode não representar o conjunto de candidatos do ENEM, em particular estudantes com menor acesso à internet. Já os temas concentram-se em assuntos como direitos humanos, política, saúde, cultura e *fake news*. As notas formam uma distribuição que se aproxima de uma normal centrada em 600. Existem 82 redações zeradas, essenciais para testar os critérios de anulação segundo a matriz de referência do Inep (2025b), além de 24 com nota máxima, também necessárias para avaliar o sistema em cenários extremos. Por fim, como as redações estão publicadas na web, os modelos de linguagem podem ter sido treinados incorporando este tipo de conteúdo.

- **Dados sensíveis.** O *dataset* não contém dados sensíveis dos autores e uma busca automática por padrões não encontrou e-mails, sites, telefones ou documentos nas redações. Menções a figuras públicas ocorrem ao longo das redações dissertativo-argumentativas conforme o esperado. Portanto, a primeiro momento, não foram identificados dados pessoais sensíveis, embora a busca não tenha sido exaustiva.

3 Arquitetura Multiagente

A arquitetura multiagente é estruturada em sete agentes independentes organizados de forma especializada: um agente orquestrador, cinco agentes especialistas (um para cada competência avaliada na redação do ENEM) e um agente revisor operando sob o paradigma LLM-as-a-judge.

3.1 Especificação dos agentes

- Agente Orquestrador
  - **Papel.** Atuar como peça central de controle, coordenando a distribuição inicial dos dados, a comunicação com os especialistas e com o revisor e a consolidação final do relatório de *feedback*.
  - **Entradas e saídas.** Recebe o par (tema, redação) e distribui esse par, junto com as tarefas, a cada um dos especialistas. Após a resposta dos especialistas e aprovação do revisor, recebe as notas e justificativas de cada uma das cinco competências e emite um relatório final numa linguagem didática contendo as notas individuais, a pontuação total, as justificativas e as recomendações de melhoria.
  - **Escopo de decisão.** Define o fluxo dos dados, formata a saída e identifica possíveis inconsistências.
  - **Critério de término.** A tarefa é finalizada quando o relatório final é gerado de forma completa e consistente com os critérios avaliados.
- Agentes Especialistas (Competências de I a V)
  - **Papel.** Avaliar de maneira crítica, rigorosa e embasada sob a ótica de uma única competência da redação do ENEM:
    1. Domínio da norma culta da língua escrita.
    2. Compreensão da proposta de redação e aplicação das áreas do conhecimento.
    3. Seleção, relação, organização e interpretação de informações, fatos e argumentos em defesa de um ponto de vista.
    4. Demonstração de conhecimento dos mecanismos linguísticos necessários para a construção da argumentação.
    5. Elaboração de proposta de intervenção para o problema abordado, respeitando os direitos humanos.
  - **Entradas e saídas.** Recebem a tupla (tema, redação, rubrica oficial e detalhada da sua respectiva competência). Emitem como saída (nota discretizada em $\{0, 40, 80, 120, 160, 200\}$, trechos do texto que suportem a decisão, justificativa didática).
  - **Escopo de decisão.** Análise e *feedbacks* autônomos restritos exclusivamente ao escopo da sua competência, relacionando as evidências encontradas no texto aos níveis definidos pela rubrica do INEP.

  - **Critério de término.** Avaliação completa e estruturada alinhada à redação e rubrica recebida.

- Agente Revisor (LLM-as-a-judge)
  - **Papel.** Auditar os resultados individuais e coletivos e controlar a qualidade das notas e *feedbacks*. Avalia de maneira crítica a coerência entre a nota atribuída, a justificativa dada e os trechos citados por cada especialista, com o objetivo de mitigar inconsistências, notas subestimadas ou superestimadas e falta de embasamento no texto original.
  - **Entradas e saídas.** Recebe a tupla (tema, redação, conjunto de avaliações gerados pelos especialistas). Emite como saída uma aprovação do relatório gerado ou uma lista de críticas direcionadas solicitando uma nova avaliação a um ou mais especialistas.
  - **Escopo de decisão.** Deve barrar notas e *feedbacks* inconsistentes e solicitar uma nova avaliação ao especialista correspondente, indicando a falha detectada.
  - **Critério de término.** A tarefa é finalizada quando o relatório final é aprovado ou quando atingimos um limite máximo de N revisões por especialista.

3.2 Modelos de linguagem

Os modelos de linguagem selecionados para cada agente baseiam-se nas necessidades de cada papel e constituem uma configuração inicial de referência. A seleção dos modelos por si só faz parte dos experimentos do presente trabalho, diferentes modelos serão testados em cada papel, para identificar empiricamente quais apresentam melhor desempenho em cada função. Os modelos citados abaixo representam apenas um ponto de partida para esses experimentos.

- **Agente Orquestrador e Revisor.** Modelos de maior capacidade (como GPT-4o ou Claude 3.5 Sonnet) por conta da necessidade de raciocínio crítico avançado, alta capacidade de pensamento no papel de LLM-as-a-judge e de sintetização de informações complexas sem gerar contradições.

- **Agentes Especialistas.** Modelos menos especializados (como GPT-4o-mini), escolha justificada por Abujadallah, Saad e Abudalfa (2025) que afirmam que estes modelos quando instruídos com rubricas detalhadas *(rubric-aligned prompting)*, atingem um desempenho comparável a avaliadores humanos com um custo computacional significativamente menor.

3.3 Raciocínio

Podemos destacar três motivos para o uso de raciocínio estruturado: (i) múltiplas informações a combinar, como trechos citados, desvios gramaticais, estrutura argumentativa e elementos da proposta de intervenção; (ii) regras e restrições para cada competência do INEP; e (iii) a resposta precisa ser verificada, já que cada nota deve ser justificada. O raciocínio requerido é predominantemente dedutivo, a regra (rubrica) é aplicada aos fatos (evidências extraídas da redação) para se chegar a uma conclusão (nota).

Portanto, a estratégia *Chain-of-Thought* de Wei et al. (2022) se mostra a mais adequada ao problema explorado. Nela, o modelo recebe instruções para gerar etapas intermediárias de raciocínio antes da resposta final. Com isso, cada especialista será capaz de gerar etapas intermediárias em suas correções, baseada na rubrica da sua respectiva competência, para estruturar uma avaliação final coerente e embasada em trechos do próprio texto. Este processo torna o processo de avaliação mais explicável e auditável, mantendo custo e latência previsíveis.

3.4 Planejamento

No contexto de trabalho do Agente Orquestrador e dos Agentes Especialistas, o planejamento estático é o mais recomendado, uma vez que não há necessidade de replanejamento, o ambiente raramente muda e as tarefas são altamente previsíveis e estáveis. Além disso, as avaliações de cada competência são independentes entre si. Então, a estratégia escolhida foi o *Plan-and-Execute* de Wang et al. (2023), no qual o plano completo é definido antes da execução e as etapas são combinadas ao final.

O Agente Revisor encara cenários de menor previsibilidade em comparação aos demais, pois o conteúdo avaliado varia a cada redação. Ainda assim, o planejamento pode permanecer estático, já que sua tarefa também é sempre semelhante. Este agente fica responsável por revisar as avaliações, apontar incongruências e, quando necessário, solicitar a reavaliação ao especialista correspondente. Essa reavaliação é a única forma de replanejamento do sistema, restrita ao especialista que falhou e limitada a um número máximo de revisões.

3.5 Memória

Os agentes operam sob o modelo de memória *stateless* (sem estado) entre execuções distintas de redações, garantindo independência entre as avaliações. Durante o processamento de uma redação específica, utiliza-se uma memória de trabalho de curto prazo mantida no contexto da conversa entre o Revisor e o Especialista durante os ciclos de ajuste e descartada ao final da avaliação. Uma memória reflexiva persistente, que acumularia lições de correções passadas, foi considerada, mas descartada por introduzir dependência entre redações e permitir a propagação de erros de uma avaliação para as seguintes.

4 Orquestração e Uso de Ferramentas

4.1 Padrão de Orquestração

O sistema opera sob o padrão de orquestração de Arquitetura com Supervisor (Planner → Parallel Specialists → Aggregator) centralizado com distribuição em paralelo *(fan-out/fan-in)* e com ciclo de revisão com reflexão *(reflection loop)*.

O Orquestrador atua como coordenador do fluxo:

- **Distribuição *(fan-out).*** Ao receber o par (tema, redação), o Orquestrador envia simultaneamente aos cinco especialistas.

- **Execução paralela.** Cada Especialista analisa a redação de maneira independente, sob o olhar exclusivo da sua competência.
- **Ciclo de reflexão.** Caso o Revisor identificar alguma inconsistência (como nota incompatível com a justificativa ou trechos citados incoerentes), o fluxo retorna apenas ao Especialista que gerou a avaliação problemática para que ela seja refeita.
- **Final *(fan-in).*** Caso todas as avaliações de Especialistas sejam aprovadas pelo Revisor, o Orquestrador organiza as notas e *feedbacks* em um relatório final único e educativo que será devolvido ao estudante.

4.2 Comunicação

A comunicação entre agentes ocorre por troca de mensagens assíncronas em formato JSON *(JavaScript Object Notation)* ao final da execução do agente atual.

1. Entrada:

```
{
  "tema": "string",
  "redacao": "string"
}
```

2. Saída de um Especialista:

```
{
  "id_competencia": "int",
  "nota": "int",
  "trechos": ["string"],
  "justificativa": "string"
}
```

3. Saída do Revisor:

```
{
    "status": "APROVADO | REVISAO",
    "feedbacks": [
        {
            "id_competencia": "int",
            "aprovado": "boolean",
            "motivo_rejeicao": "string | null"
        }
    ]
}
```

4. Saída final: documento em markdown (*.md*) estruturado com as notas de cada competência (0-200), nota total (0-1000), pontos fortes, pontos de melhoria e orientações.

4.3 Limites de execução e tratamento de falhas e divergências

- **Limite de tentativas.** Para evitar gastos desnecessários e evitar uma execução em laço infinito, padronizamos um limite de, no máximo, 2 revisões (totalizando 3 execuções no total) por especialista.
- **Timeout.** Em caso de falha de conexão ou limite de tempo, o sistema realiza 3 tentativas de reconexão, seguidas por um *fallback* com um modelo de menor latência.
- **Erros de formatação.** Validamos o formato de cada saída e caso alguma delas esteja fora do formato padronizado JSON, solicitamos novamente o agente responsável com uma instrução a mais sobre a corretude do formato.
- **Divergências não resolvidas.** Se após o limite de 2 ciclos de revisão, o Especialista e o Revisor não chegarem a um acordo, o Orquestrador intervém, mantém a menor nota e insere um alerta específico sobre essa discrepância.

4.4 Ferramentas disponibilizadas

- **Verificação de citações.** Responsável por buscar citações atreladas a autores específicos no texto, garantindo que todos eles existem e são atribuídos ao autor corretamente. É usada pelo Especialista da Competência II para conferir se as citações fornecidas ao longo do texto são válidas.
- **Verificação ortográfica.** Responsável por buscar se uma palavra está escrita de acordo com a norma culta da língua portuguesa. Busca palavras solicitadas pelos Especialistas para conferir se a grafia está correta e se seu significado é relevante para o contexto em que está inserida.
- **Extrator de conectivos e operadores argumentativos.** Busca conectivos e operadores argumentativos para mensurar uso, diversidade, repetição e posição (entre e dentro de parágrafos). É útil ao Especialista da Competência IV para avaliar coesão.
- **Validação de formato JSON.** Utilização da saída estruturada para que valida se o objeto gerado por qualquer agente segue a sintaxe JSON padronizada; é executada de maneira automática em cada saída antes de transmiti-la para o próximo passo, garantindo que só informações no formato correto serão transmitidas; retorna um valor booleano e, em caso de *False*, quais as chaves faltantes ou erros de sintaxe.

4.5 Mecanismos de Controle e Intervenção Humana

O sistema opera sob o paradigma de *Human-out-of-the-loop* durante a execução para garantir resposta imediata ao estudante. O estudante é mantido 100% fora do fluxo de avaliação da redação, sua participação limita-se a submeter o par (tema, redação) e receber o relatório.

A intervenção de humanos ocorre exclusivamente fora do fluxo de usuário, com o intuito de controlar qualidade, validar hipóteses, realizar ajustes quanto a escolha de modelos e calibrar *prompts* dos agentes.

5 Procedimentos de Avaliação

A avaliação busca responder a três perguntas: (i) as notas do sistema se aproximam das notas de corretores humanos? (ii) a arquitetura multiagente traz ganho real em relação a abordagens monolíticas? (iii) as justificativas geradas são fiéis à redação e úteis ao estudante, a um custo e latência viáveis? Os procedimentos abaixo foram desenhados para responder a cada uma delas de forma separada e mensurável.

5.1 Critérios de sucesso

Os critérios são definidos antes da execução dos experimentos finais, para evitar que os limiares sejam ajustados após a observação dos resultados:

- **Concordância com avaliadores humanos.** O sistema atinge, no conjunto de teste, QWK *(Quadratic Weighted Kappa)* na nota total de ao menos 0,60 e superior ao de todos os *baselines*. Este limiar é apenas uma base referencial e pode ser alterado posteriormente.
- **Ganho da arquitetura multiagente.** A configuração multiagente supera a abordagem monolítica com o mesmo modelo de linguagem nas métricas de concordância (objetivo) e qualidade das justificativas (subjetivo, avaliado por teste cego).
- **Viabilidade operacional.** Custo e latência por redação compatíveis com uso interativo por estudantes, espera-se tempo total de latência inferior a 2 minutos. Este limiar é apenas uma base referencial e pode ser alterado posteriormente.

5.2 Métricas

5.2.1 Concordância avaliadores humanos

Todas as métricas desta categoria são calculadas por competência (cinco escalas discretas de 0 a 200, em passos de 40) e para a nota total (0 a 1000), comparando a predição do sistema $\hat{y}_i$ com o rótulo humano y_i em cada redação i do conjunto de teste:

- **QWK.** Avalia a concordância entre duas escalas ordinais, penalizando quadraticamente o tamanho do desvio. Neste caso, avalia o quanto a nota atribuída pelo sistema multiagente concorda com as notas humanas (HUANG; WILSON, 2025).
- **Viés médio.** Identifica tendência sistemática de superestimar ou subestimar as notas. Essa métrica é relevante porque a literatura aponta avaliações excessivamente positivas como falha recorrente de LLMs em contextos educacionais (KAMALOV et al., 2026).

5.2.2 Qualidade das justificativas

Como a explicabilidade é um dos pilares da proposta, a avaliação das justificativas é tratada como resultado de mesma importância que a acurácia das notas:

- **Coerência entre nota e justificativa.** Avaliada por um modelo de linguagem juiz independente, de família diferente da dos modelos usados no sistema. O juiz recebe a rubrica da competência, a justificativa e a nota, e indica se a nota é compatível com o nível descrito na rubrica.
- **Avaliação por usuários-alvo.** Aplicação de um teste cego entre estudantes que consiste na apresentação de relatórios provenientes de sistemas monolíticos e do sistema descrito nesta metodologia. Estes estudantes respondem perguntas quantitativas e qualitativas sobre a qualidade do *feedback* recebido por ambos os sistemas.

5.2.3 Custo e latência

Para cada redação são medidos o número de *tokens* de entrada e saída por agente, o custo monetário estimado a partir das tarifas públicas dos provedores, e a latência de ponta a ponta. Reportam-se média, mediana e percentil 95 (p95) da latência, discriminando o tempo gasto nas fases de especialistas, revisão e consolidação. Como a execução dos especialistas é paralela, a latência da fase é determinada pelo especialista mais lento.

5.3 Protocolo experimental

Serão realizados experimentos quanto a: (i) variação do *prompt* descritivo da rubrica dos especialistas; e (ii) utilização de diferentes modelos de linguagem para o mesmo papel.

5.3.1 Definição da rubrica oficial

O conjunto de redações é empregado na elaboração e no ajuste dos *prompts* e na definição dos limites de revisão. Além de realizar uma avaliação final de cada configuração, depois que *prompts* e parâmetros estiverem congelados.

5.3.2 Modelos *baselines*

A Tabela 1 lista as configurações comparadas. Os modelos apresentam a abordagem monolítica com certas atribuições adicionais até se tornarem o modelo completo definido na hipótese do presente trabalho. Ao adicionar um componente por vez da arquitetura, podemos analisar sua contribuição isoladamente.

ID	Descrição
M1	Monolítico simples: um único *prompt* com as cinco competências, sem rubrica detalhada e o modelo de maior capacidade (o mesmo do Orquestrador e do Revisor).
M2	Monolítico com rubrica: um único *prompt* com a rubrica oficial completa e o modelo de maior capacidade.
M3	Modelo único: todos os agentes usam o mesmo modelo de alta capacidade, em vez de modelo menor nos especialistas, para avaliar o ganho e o custo da alocação diferenciada.
Completo	Arquitetura proposta (Seção 3): especialistas com modelo menor e ferramentas; Revisor e Orquestrador com modelo maior.

Tabela 1: Configurações avaliadas: modelos (M) comparados com a arquitetura completa.

5.4 Validade e limitações

Este protocolo experimental busca garantir robustez por meio do isolamento das variáveis ajustadas do sistema, que sustentam os ganhos de um cenário para o outro por conta da atomicidade da variação. De todo modo, são esperadas as seguintes ameaças à validade e limitações:

- **Contaminação dos dados de avaliação.** As redações estão publicadas na web e podem ter sido vistas pelos modelos durante o pré-treinamento, o que potencialmente infla o desempenho. Esse efeito não pode ser eliminado, mas afeta de forma semelhante todas as configurações comparadas, o que preserva a validade das comparações relativas.
- **Viés do modelo juiz.** Modelos de linguagem usados como avaliadores tendem a favorecer as saídas de modelos da própria família. Os mitigadores adotados são o uso de um juiz de família distinta e o uso do juiz apenas como métrica complementar.
- **Validade do *feedback*.** A simples concordância com a nota humana não implica valor pedagógico. Uma nota correta pode vir acompanhada de uma orientação pouco útil, o que motiva a avaliação humana das justificativas e o teste cego com estudantes.

6 Declaração de uso de IA generativa no processo de elaboração

Durante a preparação deste trabalho, os autores utilizaram o Google Gemini e Claude para aprimorar a clareza do texto, facilitar a busca de artigos e fontes, e auxiliar no uso da sintaxe LaTeX. Após o uso desta ferramenta/serviço, os autores revisaram e editaram o conteúdo conforme necessário e assumem total responsabilidade pelo conteúdo do trabalho submetido.

Referências

ABUJADALLAH, M.; SAAD, M.; ABUDALFA, S. Evaluating open-source llms for automated essay scoring: The critical role of prompt design. *Preprints*, 2025. Disponível em: ⟨https://doi.org/10.20944/preprints202511.1429.v1⟩. Acesso em: 20 set. 2026.

HUANG, Y.; WILSON, J. Evaluating LLM-based automated essay scoring: Accuracy, fairness, and validity. In: *Proceedings of the Artificial Intelligence in Measurement and Education Conference (AIME-Con): Works in Progress*. [s.n.], 2025. p. 71–83. ISBN 979-8-218-84229-1. Disponível em: ⟨https://aclanthology.org/2025.aimecon-wip.9/⟩. Acesso em: 18 out. 2026.

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). *Esforço Docente: Indicadores Educacionais*. Brasília, 2025. Disponível em: ⟨https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/indicadores-educacionais/esforco-docente⟩. Acesso em: 20 set. 2026.

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). *A redação do ENEM: Cartilha do Participante*. Brasília, 2025. Disponível em: ⟨https://download.inep.gov.br/publicacoes/institucionais/avaliacoes_e_exames_da_educacao_basica/a_redacao_no_enem_2025_cartilha_do_participante.pdf⟩. Acesso em: 18 out. 2026.

KAMALOV, F. et al. *Evolution of AI in Education: Agentic Workflows*. 2026. Disponível em: ⟨https://arxiv.org/abs/2504.20082⟩. Acesso em: 20 set. 2026.

MARINHO, J.; ANCHIÊTA, R.; MOURA, R. Essay-br: a brazilian corpus of essays. In: *Anais do III Dataset Showcase Workshop*. Online: Sociedade Brasileira de Computação, 2021. p. 53–64. Disponível em: ⟨https://sol.sbc.org.br/index.php/dsw/article/view/17414⟩. Acesso em: 13 out. 2026.

MARINHO, J.; ANCHIÊTA, R.; MOURA, R. Essay-br: a brazilian corpus to automatic essay scoring task. *Journal of Information and Data Management*, Sociedade Brasileira de Computação, v. 13, n. 1, p. 65–76, 2022. Disponível em: ⟨https://sol.sbc.org.br/journals/index.php/jidm/article/view/2340⟩. Acesso em: 13 out. 2026.

WANG, L. et al. *Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models*. 2023. Disponível em: ⟨https://arxiv.org/abs/2305.04091⟩. Acesso em: 18 out. 2026.

WEI, J. et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, v. 35, p. 24824–24837, 2022. Disponível em: ⟨https://arxiv.org/abs/2201.11903⟩. Acesso em: 18 out. 2026.